

EARLY-LIFE PREDICTIVE ANALYTICS

초기 100 Cycle 기반 배터리 수명 예측

어떤 초기 신호가 배터리의 미래 수명을 설명하는가?

초기 Capacity 자체보다 **cycle 10에서 100까지 전압별 방전곡선이 변한 정도인 $\Delta Q(V)$** 가 세 Batch에서 미래 수명과 더 일관된 관계를 보였다. Day 2는 $\Delta Q(V)$ 를 Core Feature로 두고 Capacity, Sensor, Charging Feature의 추가 가치를 단계적으로 검증한다.

● ESS RACK

139

원본 Battery Cell

129

유효 Cycle Life Label

100

Early-cycle Window

작성자

U094 이수현

작성일

2026-10-01 (목)

범위

Batch 1 / Batch 2 / Batch 3

문제

Cycle Life Regression

REPORT MAP

초기 신호에서 Day 2 전략까지

분석은 데이터 구조를 먼저 고정하고, 다섯 개 EDA 질문의 근거를 거쳐, 재현 가능한 Regression 검증 전략으로 수렴한다.

CONTEXT & DATA

문제와 데이터

03-05

Executive Summary	03
문제 정의	04
데이터 이해와 품질	05

EXPLORATORY ANALYSIS

다섯 개 EDA 질문

06-12

Q1. Target 분포	06
Q2. Capacity와 Knee	07
Q3. $\Delta Q(V)$ 핵심 분석	08-09
Q4-5. 충전 조건과 중복	10-12

MODEL STRATEGY

Feature와 모델 전략

13-16

EDA 종합	13
Feature Engineering	14
Regression 선택 이유	15
모델·Ablation 설계	16

VALIDATION & NEXT STEP

검증과 실행

17-18

Validation Strategy	17
한계와 Day 2 실행 순서	18

읽는 방법

QUESTION

무엇을 확인하는가

EVIDENCE

어떤 수치와 그림인가

INTERPRET

어디까지 설명 가능한가

DECIDE



Day 2에 무엇을 남기는가

0. EXECUTIVE SUMMARY


초기 열화의 “크기”보다 “변화 형태”가 수명을 더 잘 설명했다

이 프로젝트는 배터리를 끝까지 시험하지 않고 초기 100 cycle만으로 처음부터 수명 종료까지의 총 Cycle Life를 예측한다. 139개 Cell을 점검하고 수명 정답이 있는 129개를 동일한 기준으로 비교했다. Batch별 수명 분포는 크게 달랐고, 초기 Capacity 자체의 관계는 약했지만 $\Delta Q(V)$ 는 세 Batch에서 일관된 강한 관계를 보였다.

가장 중요한 발견



보고서의 질문 흐름



Day 2 한 줄 전략

$\Delta Q(V)$ 를 중심에 두고 서로 다른 Feature군을 하나씩 추가하며, Batch 1 CV와 고정 Hold-out에서 검증한 뒤 Batch 2를 External Test로 한 번 평가한다.

1. 문제 정의

전체 수명을 기다리지 않고 초기 100 Cycle로 미래를 예측한다

배터리의 실제 수명을 확인하려면 수백에서 수천 번 충·방전을 반복해야 한다. 초기 데이터만으로 최종 수명을 예측하면 ESS 점검·교체 시점을 더 일찍 계획하고 장기간 시험의 시간과 비용을 줄일 수 있다.


Cycle Life

Cycle은 충전과 방전을 한 번 수행한 단위다. **Cycle Life**는 처음 사용한 시점부터 SOH 80%에 해당하는 EOL까지 버틴 총 cycle 수다.

Target 주의

cycle_life는 “100 cycle 이후 남은 수명”이 아니라 **처음부터 EOL까지의 총 수명**이다.

Input → Regression Model → Target



Day 1의 다섯 질문

Q1

Target은 Batch마다 다른가?

예측 범위와 외부 일반화 위험을 확인한다.

Q2

초기 Capacity에서 차이가 보이는가?

가장 직관적인 신호의 한계를 확인한다.

Q3

$\Delta Q(V)$ 가 수명 차이를 포착하는가?

초기 변화 형태의 설명력을 확인한다.

Q4

충전 조건이 수명을 설명하는가?

빠른 충전의 단순 규칙을 검증한다.

Q5

어떤 Feature군을 Day 2 후보로 남길 것인가?

관계의 크기, Batch 간 일관성, Feature 중복을 함께 판단한다.

2. 데이터 이해


독립 Sample은 Cycle이 아니라 Battery Cell이다

2.1 Dataset

Batch는 서로 다른 시기와 실험 조건에서 수집된 Cell 묶음이다. Day 1은 세 Batch를 동일한 기준으로 비교하되, Day 2 모델 선택은 Batch 1 안에서 수행한다.

Dataset	전체 Cell	Target 보유	Target 결측
Batch 1	46	46	0
Batch 2	47	39	8
Batch 3	46	44	2
합계	139	129	10

2.2 데이터 구조



EDA에서는 cycle별 변화를 펼쳐 살펴보지만, Day 2에서는 초기 100 cycle을 요약해 Cell 한 개당 Feature 행 한 개를 만든다. Cycle 기록이 많아도 독립 학습 Sample은 129개 수준이다.

2.3 먼저 확인한 데이터 품질

Placeholder

Batch 1의 모든 Cell은 첫 summary cycle에 실측이 아닌 0 채움 값이 있어 cycle 2부터 초기 통계를 계산했다.

Missing Target

Batch 2의 8개, Batch 3의 2개 Cell은 cycle_life가 결측이다.

Sensor Availability

Batch 2의 7개 Cell은 초기 IR이 미가용이고, 3개 Cell은 초기 Tmin이 비정상이다.

Physical Range

첫 cycle placeholder와 일부 물리 범위 밖 QD 측정은 초기 Feature 계산에서 제외했다.

데이터 처리 원칙

실제 측정값과 결측 표현을 구분하고, 이상값이 있다는 이유만으로 원본 Cell을 임의 삭제하지 않았다. 결측 Cycle Life도 관측 기록 길이로 대체하지 않았다.

질문

근거

핵심 발견

해석

Day 2

3.1 QUESTION 1

세 Batch의 수명 분포는 같지 않았다

왜 확인했는가?

모델이 맞아야 할 Target의 범위가 Batch마다 같은지, 학습 성능을 외부 데이터에 그대로 기대할 수 있는지 확인했다.

어떻게 확인했는가?

Target이 있는 Cell의 histogram·누적분포·중앙값·수명 구간 비율을 비교하고, 분포 차이를 통계 검정으로 보조 확인했다.




Figure 1. Batch별 Cycle Life 분포와 누적분포

이 그림에서 볼 것

Batch 2는 짧은 수명 쪽에 집중되어 있고 Batch 3은 긴 수명 쪽으로 이동해 있다. 세 Batch가 같은 Target 분포에서 나온 것처럼 보이지 않는다.

Batch	Target 수	중앙값	분포의 특징
Batch 1	46	858.5	500~1,000 cycle에 주로 분포
Batch 2	39	472.0	500 cycle 미만인 71.8%
Batch 3	44	1,005.5	1,000 cycle 초과가 52.3%

핵심 발견

세 중앙값은 472.0~1,005.5 cycle로 크게 달랐다. Kruskal-Wallis $H=53.925$, $p=1.95 \times 10^{-12}$ 로 분포 차이도 확인됐다.

해석

실험 시기·충전 프로토콜·Cell 구조가 함께 반영됐을 수 있어 특정 요인의 인과효과로 단정할 수 없다.

Day 2 시사점

Batch 1에서 Feature와 모델을 선택한 뒤 Batch 2를 External Test로 분리하고, Batch 3에서 추가적인 분포 이동을 확인한다.

질문

근거

핵심 발견

해석

Day 2

3.2 QUESTION 2


수명 차이는 초기 Capacity만으로 잘 보이지 않았다

왜 확인했는가?

배터리가 노화하면 QD가 감소하므로 초기 Capacity 수준이나 변화만으로 미래 수명을 구분할 수 있는지 확인했다.

어떻게 확인했는가?

Cycle 2~100의 QD 평균·기울기와 전체 수명 동안의 대표 열화곡선을 비교했다. Knee Point는 용량 감소가 급격히 가속되기 시작하는 시점이다.



이 그림에서 볼 것

초기 구간에서는 장수명·중간수명·단수명 Cell의 Capacity가 비슷하게 유지되고 일부는 소폭 증가한다. 뚜렷한 차이는 수명이 진행된 뒤 급격한 열화가 시작될 때 나타난다.

0.242

QD 평균 ρ / Batch 1

0.117

QD 평균 ρ / Batch 2

0.162

QD 평균 ρ / Batch 3

핵심 발견

초기 QD 평균과 수명의 Batch별 관계는 모두 약했다. QD slope도 Batch 1은 0.479, Batch 2는 -0.271로 방향이 달랐다.

강하지만 쓸 수 없는 신호

전체 곡선에서 계산한 knee cycle과 Cycle Life는 $\rho=0.934$ 였지만 미래 구간이 필요하다.

해석 - Data Leakage

전체 수명을 본 뒤 계산한 knee는 예측 시점에 알 수 없다. 강한 상관만 보고 입력으로 사용하면 정답의 미래정보가 모델에 새어 들어간다.

Day 2 시사점

초기 Capacity는 baseline·보조 Feature로 남기고 knee는 제외한다. 다음 질문에서는 100 cycle 안에서 볼 수 있는 더 미세한 변화인 $\Delta Q(V)$ 를 확인한다.

질문

근거

핵심 발견

해석

Day 2

3.3 QUESTION 3 / CORE ANALYSIS

ΔQ(V)는 초기 100 Cycle 안에서 수명 차이를 포착했다

ΔQ(V)는 무엇인가?

Cycle 10과 cycle 100에서 같은 전압을 비교했을 때 방전 가능한 용량이 얼마나 달라졌는지를 나타낸다.


$$\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$$

왜 확인했는가?

초기 Capacity 절대값의 차이가 작았기 때문에 “얼마나 큰가”보다 전압 별 방전곡선의 **변화 형태**가 수명을 설명하는지 확인했다.

어떻게 확인했는가?

실제 cycle 10~100의 Qdlin을 공통 전압축에서 빼고, 각 Batch 수명 상·하위 25%의 중앙곡선과 IQR을 비교했다.



이 그림에서 볼 것

단수명 그룹은 장수명 그룹보다 cycle 10→100 사이의 방전곡선 변화 폭이 크다. 이 차이는 특정 Batch에만 나타나지 않고 세 Batch에서 같은 방향으로 관찰된다.

Capacity Level

초기 QD 평균은 배치 안에서 수명과 관계가 약했다.

Change Shape

ΔQ(V)는 눈에 잘 보이지 않는 초기 열화 차이를 전압 구간별 형태로 드러냈다.

다음 근거

곡선 차이가 “보이는 것”에서 끝나지 않도록, ΔQ(V) 변화의 크기를 로그분산으로 요약해 Cycle Life와의 관계를 Batch별로 확인했다.

질문

근거

핵심 발견


해석

Day 2

3.3 QUESTION 3 / EVIDENCE TO DECISION

ΔQ(V)는 세 Batch에서 같은 방향의 강한 관계를 보였다

질문 3. 초기 ΔQ(V) 신호의 설명력



이 그림에서 볼 것

ΔQ(V) 로그분산이 커질수록 Cycle Life가 짧아지는 방향이 반복된다. 전체 상관 하나가 아니라 Batch별 방향이 유지된다는 점이 핵심이다.

Batch	Spearman ρ	관계	판단
Batch 1	-0.871	강한 음의 관계	학습 Batch에서 핵심 신호
Batch 2	-0.709	같은 방향	외부 Batch에서도 유지
Batch 3	-0.797	같은 방향	추가 Batch에서도 유지

핵심 발견

초기 방전곡선 변화가 클수록 최종 수명이 짧아지는 방향이 일관됐다. 전체 데이터의 ΔQ 로그분산 상관관계는 $\rho = -0.892$ 였다.

해석

ΔQ(V)는 초기 QD 평균보다 작은 열화 차이에 민감한 신호로 볼 수 있다. 다만 이는 연관성이며 인과관계는 아니다.

중복 주의

ΔQ 분산·표준편차·로그분산·IQR은 같은 곡선의 변화를 비슷하게 요약한다. 모두 넣으면 정보가 늘기보다 중복이 커질 수 있다.

Day 2 시사점

ΔQ(V)를 Core Feature군으로 선정하되, Batch 1 CV와 규제를 통해 대표 변수를 고른다. 높은 상관의 ΔQ 파생변수를 전부 고정 투입하지 않는다.

질문

근거

핵심 발견

해석

Day 2

3.4 QUESTION 4

빠른 충전 하나만으로 수명을 설명할 수 없었다

왜 확인했는가?

충전 속도는 열화에 영향을 줄 수 있으므로 Charging Policy가 수명 차이를 추가로 설명하는지 확인했다.

어떻게 확인했는가?

정책 문자열을 1단계 C-rate·전환 SOC·2단계 C-rate로 나누고, 산점도와 정책별 평균·표본 수·bootstrap 95% 신뢰구간을 비교했다.

C-rate는 배터리 용량 대비 충전 전류의 크기로, 값이 클수록 더 빠르게 충전한다는 뜻이다.

질문 4. 충전 조건과 배터리 수명



Figure 5. 충전 조건과 Cycle Life의 관계

이 그림에서 볼 것

같은 C-rate에서도 수명이 넓게 퍼지고 정책별 평균의 불확실성도 크다. “빠른 충전 = 짧은 수명”이라는 하나의 직선 규칙으로 설명하기 어렵다.

범위	1단계 C-rate ρ	판단
전체	-0.027	사실상 관계 없음
Batch 1	-0.483	음의 관계
Batch 2	0.055	방향이 뒤집히며 매우 약함
Batch 3	-0.229	음의 방향이지만 약함

핵심 발견

Batch 1의 음의 관계는 Batch 2·3에서 같은 크기로 반복되지 않았다. 일부 정책은 n=1~2라 평균 수명의 불확실성도 크다.

해석

Batch, Cell 구조, 온도 등이 함께 섞여 있을 수 있으므로 충전 속도의 인과효과로 단정하지 않는다.

Day 2 시사점

정책 문자열 전체를 주요 Feature로 고정하지 않는다. C-rate와 switch SOC를 연속형 후보로 만들고 ΔQ 모델에 추가했을 때 MAPE가 줄어드는지 검증한다.

질문

근거

핵심 발견

해석

Day 2

3.5 QUESTION 5

높은 상관보다 중요한 것은 일관성과 중복 제거였다

왜 확인했는가?

상관이 큰 Feature를 많이 넣는다고 예측이 자동으로 좋아지지는 않는다. Batch마다 방향이 유지되는지와 같은 정보가 반복되는지 확인했다.

어떻게 확인했는가?

Capacity·IR·Temperature·Charge Time·Charging Condition· ΔQ Feature군의 Pearson·Spearman 상관과 Batch별 방향을 함께 비교했다.




Figure 6. 초기 Feature 간 상관관계

이 그림에서 볼 것

ΔQ 분산·표준편차·로그분산 등은 서로 거의 같은 정보를 표현한다. 이런 변수를 동시에 많이 넣으면 작은 데이터에서 모델 계수가 불안정해질 수 있다.

Consistency

전체 상관보다 Batch 1·2·3에서 관계 방향이 유지되는지를 우선한다.

Redundancy

같은 정보를 반복하는 Feature는 대표 변수 선택 또는 규제로 통제한다.

질문

근거

핵심 발견

해석

Day 2

3.5 QUESTION 5 / FEATURE GROUPS

Feature 순위가 아니라 Feature군의 역할을 결정했다

Feature군	Cycle Life와의 일관성	중복·품질 이슈	Day 2 판단
$\Delta Q(V)$	세 Batch에서 강하고 같은 방향	파생변수끼리 중복이 매우 큼	Core / 대표 변수 선택
Capacity	평균 관계는 약하고 slope 방향이 다름	수준·변화량 간 중복 가능	Baseline·보조 후보
IR	관계가 약하고 Batch별 방향이 다름	Batch 2 일부 초기값 미가용	Incremental 후보
Temperature	대부분 약하거나 방향이 다름	Tavg·Tmax 등이 서로 중복	대표 변수만 검증
Charge Time	Batch 1·2에서 관계 방향이 반대	C-rate의 대리 정보 가능	추가 가치 확인
Charging	전체 관계가 약하고 불일치	정책별 표본이 작음	마지막 단계에서 검증

핵심 발견

$\Delta Q(V)$ 가 가장 일관됐다

세 Batch에서 가장 강하고 방향이 일관된 Feature군은 $\Delta Q(V)$ 였다. 다른 Feature군은 일부 Batch에서 관계가 보여도 다른 Batch에서 약해지거나 방향이 바뀌었다.

해석

전체 상관은 부풀려질 수 있다

Batch 간 평균 차이가 큰 상태에서 데이터를 합치면 상관이 커질 수 있다. 따라서 전체 순위보다 Batch별 일관성을 우선한다.


다중공선성

ΔQ 파생변수 여러 개를 동시에 넣으면 “정보가 많아지는 것”이 아니라 같은 정보를 반복해 넣을 수 있다. 작은 데이터에서는 모델 계수와 중요도가 split에 따라 흔들릴 위험이 있다.

Day 2 시사점

높은 상관 Feature를 많이 넣지 않는다. ΔQ 를 중심으로 서로 다른 정보를 주는 Feature군을 하나씩 추가하고 Ridge·ElasticNet 규제와 Feature Ablation으로 실제 개선 여부를 판단한다.

Q1~Q5가 만든 결론



4. EDA에서 무엇을 배웠는가?

다섯 질문은 하나의 모델 전략으로 연결된다

질문	핵심 발견	의미	Day 2 결정
Cycle Life	Batch별 수명 분포가 다름	외부 일반화가 쉽지 않음	Batch 2 별도 평가
Capacity	초기 절대값 차이는 제한적	단순 Capacity만으로 부족	Baseline 역할
$\Delta Q(V)$	가장 일관된 초기 신호	초기 열화 shape가 중요	Core Feature
Charging	Batch별 관계가 다름	단순 C-rate 법칙이 없음	추가 Feature로 검증
Sensor 중복	일부 관계가 있지만 중복이 큼	Feature 수 통제가 필요	규제 + Ablation

EDA가 만든 하나의 결론

초기 Capacity만으로는 미래 수명 차이가 잘 드러나지 않았다. 그러나 같은 전압에서 cycle 10과 100의 방전곡선 변화를 비교한 $\Delta Q(V)$ 는 세 Batch에서 일관된 관계를 보였다. 따라서 Day 2는 ΔQ 를 중심에 두고 다른 Feature군의 추가 가치를 검증한다.

분석에서 모델로 넘어가는 논리



Research Rigor

미래정보를 배제한다

Knee와 EOL처럼 설명력은 높아도 예측 시점에 알 수 없는 값은 사용하지 않는다.

Decision Clarity

후보와 확정을 구분한다

Day 1은 후보군을 좁히고, Day 2의 CV와 Ablation이 최종 Feature를 결정한다.

5. FEATURE ENGINEERING STRATEGY

최종 채택이 아니라 검증할 후보와 순서를 정했다

Day 1의 역할은 Feature를 확정하는 것이 아니라 과적합과 중복을 피하도록 **Day 2에서 검증할 후보군과 투입 순서**를 설계하는 것이다.

Core Feature

 $\Delta Q(V)$

delta_q_log10_var를 대표 후보로 둔다. Cycle 10~100만 사용하고 세 Batch에서 같은 방향의 강한 관계를 보였다.

Baseline Feature

초기 Capacity

초기 QD 평균과 slope를 가장 단순한 기준으로 사용해 ΔQ 가 baseline보다 얼마나 개선하는지 비교한다.

Incremental Feature

Sensor와 Charging

IR·Temperature·Charge Time·C-rate·switch SOC를 군별로 추가해 ΔQ 에 없는 정보를 주는지 확인한다.

Excluded Feature

미래정보

Knee, EOL, cycle_life 파생값, cycle 100 이후 측정은 상관이 높아도 입력에서 제외한다.

Feature군	역할	Day 1 근거	Day 2 사용 방식
$\Delta Q(V)$	Core	세 Batch에서 강하고 일관됨	대표 Feature 선택
Capacity	Baseline	단독 관계가 제한적	F0 기준선
Sensor	Incremental	일부 Batch에서만 관계	군별로 하나씩 추가
Charging	Incremental	관계가 비일관적	추가 MAPE 개선 확인
Knee·EOL	제외	미래정보가 필요함	사용 금지

대표 변수 선택

ΔQ 최소값·분산·표준편차·로그분산·면적·분위수는 같은 곡선에서 나온다. 모두 고정하지 않고 CV와 규제를 통해 대표성을 비교한다.

설계 원칙

높은 상관계수의 개수가 아니라, 새로운 Feature군이 동일한 split에서 MAPE를 얼마나 안정적으로 줄였는지를 최종 근거로 사용한다.

6. 왜 REGRESSION인가?

“긴가, 짧은가”보다 “몇 Cycle인가”를 예측한다

Classification

범주를 맞춘다

장수명 / 단수명처럼 정해진 등급 중 하나를 예측

Regression

숫자를 맞춘다

처음부터 EOL까지 총 몇 cycle인지 연속값으로 예측

왜 수명 숫자가 필요한가?

ESS 유지보수와 교체 시점을 정량적으로 판단하려면 “긴가, 짧은가”보다 “몇 cycle인가”가 더 직접적인 정보다. Target을 연속형 cycle_life로 두는 Regression을 선택한다.

Primary Metric - MAPE

Meaning

MAPE는 예측 오차를 실제 수명 대비 백분율로 나타낸다.

예: MAPE 10%라면 평균적으로 실제 수명의 약 10% 정도를 벗어 났다는 뜻이다.

Benchmark

원논문 테스트 오차 9.1%

성능을 가늠하는 참고값이며, 현재 전처리·Feature·split이 완전히 같지 않으므로 동일 조건 재현이라고 표현하지 않는다.

7.1 데이터 특성이 말해주는 모델 조건

Small Sample

독립 Sample은 Cycle이 아니라 Cell이며 Batch 1은 46개다.

High Redundancy

ΔQ 파생변수와 온도 Feature는 서로 비슷한 정보가 많다.

Possible Nonlinearity

ΔQ 와 수명의 관계가 강해도 완전히 선형이라고 보장할 수 없다.

Uncertain Incremental Value

Sensor와 Charging이 ΔQ 에 추가 정보를 주는지는 아직 불확실하다.

모델 비교 원칙

복잡한 모델 하나를 바로 선택하지 않고, 단순 baseline부터 규제 선형모델과 비선형 모델을 동일한 검증 조건에서 비교한다.

7. DAY 2 MODELING STRATEGY

모델 수를 늘리기보다 선택 이유를 비교한다

7.2 비교할 모델과 선택 이유

모델	선택 이유
Baseline 중앙값	ML 모델이 단순 예측보다 실제 가치를 만드는지 확인
Linear Regression	가장 단순한 선형 관계와 계수 방향 확인
Ridge	작은 데이터와 다중공선성에 대응하도록 계수를 안정화
ElasticNet	중복 Feature의 계수를 축소하고 일부를 선택할 가능성
Gradient Boosting / LightGBM	ΔQ ·Sensor·Charging 사이의 비선형 관계와 조합 효과 검증

Deep Learning을 우선하지 않는 이유

Cycle 기록은 많아도 독립 Sample은 Cell 수십 개 수준의 표 형태 데이터다. 큰 신경망의 복잡도를 뒷받침할 학습 표본이 부족해 과적합 위험이 크다.

7.3 Feature Ablation - 무엇이 실제로 성능을 높였는가?

단계	사용 Feature	확인할 질문
F0	Capacity baseline	가장 단순한 초기 용량만으로 어느 정도 예측되는가?
F1	ΔQ	변화 형태가 baseline보다 MAPE를 줄이는가?
F2	ΔQ + Capacity trend	용량 변화 속도가 추가 정보를 주는가?
F3	F2 + Sensor	IR·Temperature·Charge Time이 개선을 만드는가?
F4	F3 + Charging Condition	C-rate·switch SOC가 마지막 추가 가치를 주는가?

Ablation이 주는 객관적 근거

새로운 Feature군을 하나씩 추가하고 동일한 CV split에서 평균 MAPE와 fold 편차가 실제로 개선되는지 본다. 이 결과가 상관계수보다 직접적인 Feature 선정 근거가 된다.

MAPE

평균 예측 오차

STD


Fold 간 안정성

GAP

과적합·일반화 차이

8. VALIDATION STRATEGY

모델 개발과 외부 평가를 명확히 분리한다



Development

Batch 1 안에서 선택

Batch 1 일부를 고정 Hold-out으로 먼저 분리한다. 나머지 개발 데이터의 K-fold CV로 F0~F4와 모델 후보를 비교한다.

External Test

선택 이후 한 번 평가

선택이 끝난 단일 pipeline만 Batch 2에서 평가한다. Batch 2의 정답을 Feature나 설정 선택에 되먹임하지 않는다.

Data Leakage 방지

- ✓ 모델 입력은 cycle 100까지의 정보만 사용한다.
- ✓ Knee, EOL 등 미래정보를 사용하지 않는다.
- ✓ Cell 한 개를 Sample 한 개로 유지하고 동일 Cell을 Train과 Validation 양쪽에 넣지 않는다.
- ✓ Imputer, scaler, encoder는 각 Train fold에서만 fit한다.
- ✓ Batch 2·3의 정답으로 Feature나 모델 설정을 반복 선택하지 않는다.

최종 선택 기준

CV MAPE

평균 예측 오차

Fold 편차

Split에 따른 안정성

Hold-out Gap

과적합 여부

Explainability

Feature 수와 판단 가능성

Generalization 판단

Batch 3은 Batch 2와도 다른 분포에서 결과가 얼마나 유지되는지 보는 추가 분석에 사용한다. 외부 성능 저하 자체도 Batch Shift를 보여주는 중요한 결과로 해석한다.

9. 한계와 다음 단계

결과의 범위를 명확히 하고 Day 2에서 검증한다

Small Sample

Cell 수가 작다

복잡한 모델의 작은 성능 차이는 split에 따라 달라질 수 있다. CV 평균과 편차를 함께 보고 단순한 모델을 우선한다.

Sparse Policy Groups

정책별 표본은 더 작다

정책별 평균을 인과효과로 해석하지 않고 연속형 충전조건에 추가 예측가치만 검증한다.

Missing Target

Cycle Life 결측 10개

중도절단된 장수명 Cell일 수 있어 관측 분포가 치우칠 수 있다. 기록 길이로 임의 보정하지 않는다.

Batch Shift

분포 차이가 크다

Batch 1 CV와 Batch 2·3 성능을 분리해 보고하고 외부 성능 저하도 중요한 결과로 해석한다.

Lab-to-Field Gap

실험실 Cell을 실제 ESS로 직접 일반화할 수 없다

실제 ESS의 온도 구배, Cell 불균형, 운영 부하를 모두 대표하지 않으므로 현장 수명으로 직접 해석하지 않는다.

Day 2 실행 순서

01

고정 Split

Batch 1 Hold-out 분리

02

F0~F4 Ablation

Feature 기여도 확인

03

Model 비교

선형·규제·비선형

04

External Test

Batch 2 한 번 평가

최종 성공 기준

Feature 수를 늘리는 것이 아니라, ΔQ 중심의 작은 Feature 집합이 외부 Batch에서도 안정적인 MAPE를 만드는지 확인하는 것이다.

CONCLUSION

초기 100 Cycle 안에도 미래 수명의 신호는 있었다.

그 신호는 Capacity의 절대 수준보다 전압별 방전곡선이 변하는 형태인 $\Delta Q(V)$ 에서 가장 일관되게 나타났다.